

Universidad de la República - Facultad de Ingeniería



CURSO 2023 : FUNDAMENTOS DE OPTIMIZACIÓN

GRUPO 133

Guido Dinello
5.031.022-5

Mathías Ramilo
5.665.788-5

TAREA FINAL

Índice

1. Verifique que la solución no es única.	
Sugerencia: dada una solución X , busque soluciones de la forma XC , con C matriz de tamaño y características a definir.	
	2
1.1. Enfoque	2
1.2. Generación de la matriz aleatoria C	2
1.3. Descomposición QR	2
1.4. Generación de la matriz combinada XC	2
1.5. Cálculo del valor funcional	2
1.5.1. Verificación de la no unicidad	2
2. Compruebe numericamente que la función objetivo no es convexa. Sugerencia, tome dos soluciones, basandose en el ítem anterior.	
	3
2.1. Definición de función convexa	3
2.2. Comprobación numérica	3
3. Calcule el gradiente de la función objetivo, y verifique numéricamente el resultado.	
	3
3.1. Cálculo del gradiente	3
3.2. Verificación numérica del resultado	4
4. Implemente un método de descenso por gradiente para encontrar un punto crítico de la función. Compare la solución y su valor funcional con la solución dada por la descomposición espectral de A.	
	5
4.1. Implementación	5
4.2. Comparación de Resultados	5

1. Verifique que la solución no es única.

Sugerencia: dada una solución X , busque soluciones de la forma XC , con C matriz de tamaño y características a definir.

1.1. Enfoque

Considerando soluciones de la forma XC siendo X solución. Para que el producto matricial este bien definido entre las matrices para la expresión $X' = XC$ donde tanto X' como X son solución al problema y por ende poseen dimensiones $n \times d$ entonces C debe tener dimensiones $d \times d$.

Por otro lado, podemos realizar la sustitución en la expresión original obteniendo:

$$A - XX^t = A - XC(XC)^t = A - XCC^tX^t$$

Observemos que si $CC^t = Id$ entonces obtenemos la ecuación inicial, por lo que si X minimiza $\|A - XX^t\|_F^2$ se sigue que XC también lo hará.

Por ende, C debe ser una matriz ortogonal.

1.2. Generación de la matriz aleatoria C

Se genera una matriz aleatoria C de tamaño $d \times d$ utilizando la función `rand` del paquete `numpy.random`.

1.3. Descomposición QR

Se realiza la descomposición QR de la matriz C , donde Q es una matriz ortogonal y R es una matriz triangular superior. Esto se logra utilizando la función `np.linalg.qr`.

1.4. Generación de la matriz combinada XC

Obtenemos XC de tamaño $n \times d$ multiplicando la matriz solución dada X_{svd} y la matriz Q obtenida en la descomposición QR. Es decir $XC = X_{\text{svd}}Q$.

1.5. Cálculo del valor funcional

Se calcula el valor funcional utilizando la función $f(X)$ definida en el problema.

$$f(X) = \|A - XX^t\|_F^2$$

Resultados empíricos obtenidos.

$$f(XC) \approx 8045,3111$$

$$f(X_{\text{svd}}) \approx 8045,3111$$

1.5.1. Verificación de la no unicidad

Como podemos observar anteriormente tanto XC como X_{svd} son soluciones válidas para el problema planteado para cualquier C matriz ortogonal de tamaño $d \times d$.

2. Compruebe numericamente que la funcion objetivo no es convexa. Sugerencia, tome dos soluciones, basandose en el item anterior.

2.1. Definición de función convexa

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se dice que es convexa si para cualquier par de puntos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ y cualquier $\alpha \in [0, 1]$, se cumple la siguiente desigualdad:

$$f(\alpha \mathbf{x} + (1 - \alpha) \mathbf{y}) \leq \alpha f(\mathbf{x}) + (1 - \alpha) f(\mathbf{y})$$

En otras palabras, una función es convexa si el segmento de línea entre dos puntos en su gráfica siempre se encuentra por encima o en el mismo nivel que la función en esos puntos.

2.2. Comprobacion numerica

Utilizando las 2 soluciones obtenidas en el inciso anterior y tomando $\alpha = 0,5$ verificamos que no se cumple la desigualdad.

$$f\left(\frac{1}{2}X_{\text{svd}} + \left(1 - \frac{1}{2}\right)XC\right) \leq \frac{1}{2}f(X_{\text{svd}}) + \left(1 - \frac{1}{2}\right)f(XC)$$

$$11612,7977 \leq 8045,3111$$

Por lo que podemos afirmar que la funcion no es convexa.

3. Calcule el gradiente de la función objetivo, y verifique numéricamente el resultado.

3.1. Calculo del gradiente

Sea $f(X) = \|A - XX^T\|^2$

Siguiendo la definicion de la norma Frobenius: $\|A\|_F = \sqrt{\text{tr}(AA^H)}$

Podemos reescribir a $f(X)$ como:

$$\begin{aligned} & ((\text{tr}([A - XX^T][A - XX^T]^T))^{(1/2)})^2 = \\ & \text{tr}([A - XX^T][A^T - (XX^T)^T]) = \\ & \text{tr}([A - XX^T][A^T - XX^T]) = \\ & \text{tr}(AA^T - AXX^T - XX^T A^T + XX^T XX^T) \end{aligned}$$

Usando la propiedad de la traza $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$

$$\text{tr}(AA^T) - \text{tr}(AXX^T) - \text{tr}(XX^T A^T) + \text{tr}([XX^T]^2)$$

Utilizando la propiedad de la traza $\text{tr}(ABC) = \text{tr}(BCA) + \text{tr}(CAB)$ y $\text{otr}(AB) = \text{tr}(BA)$

$$\begin{aligned} & \text{tr}(AA^T) - \text{tr}(AXX^T) - \text{tr}(A^T XX^T) + \text{tr}((XX^T X)X^T) = \\ & \text{tr}(AA^T) - \text{tr}(AXX^T) - \text{tr}(A^T XX^T) + \text{tr}(X^T XX^T X) \end{aligned}$$

Derivando respecto de X y utilizando la linealidad del operador gradiente en conjunto con las siguientes igualdades¹:

$$\frac{\partial}{\partial X} [\text{Tr}[X^T X X^T X]] = 4X X^T X \quad (123 \ B = C = Id)$$

$$\frac{\partial}{\partial X} [\text{Tr}(X^T X B)] = X B^T + X B \quad (113)$$

$$\frac{\partial}{\partial X} [\text{Tr}(B X X^T)] = B X + B^T X \quad (109)$$

Tenemos que:

$$\frac{\partial}{\partial X} [\text{tr}(A A^T)] = 0$$

$$\frac{\partial}{\partial X} [\text{tr}(A X X^T)] = A X + A^T X$$

$$\frac{\partial}{\partial X} [\text{tr}(A^T X X^T)] = A^T X + A^{TT} X = A^T X + A X$$

$$\frac{\partial}{\partial X} [\text{tr}(X^T X X^T X)] = 4X X^T X$$

$$\begin{aligned} \frac{\partial}{\partial X} f(X) &= -A X - A^T X - A^T X - A X + 4X X^T X = \\ &= -2(A X + A^T X) + 4X X^T X \end{aligned}$$

Finalmente, dado que A es simétrica ($A^T = A$):

$$\frac{\partial}{\partial X} f(X) = -4A X + 4X X^T X = 4(-A + X X^T) X$$

3.2. Verificación numérica del resultado

Utilizando la implementación 1 para estimar el gradiente numérico obtuvimos un valor para la norma de la diferencia con el gradiente hallado analíticamente de 0,0003884.

Algorithm 1 Numerical approximation of the gradient using incremental ratios

```

function GRAD_NUMERICO( $X$ )
   $\text{eps} \leftarrow 1e-7$ 
   $\text{grad} \leftarrow \text{zeros}(X.\text{shape})$ 
  for  $\text{row} \leftarrow 0$  to  $X.\text{rows} - 1$  do
    for  $\text{col} \leftarrow 0$  to  $X.\text{cols} - 1$  do
       $h \leftarrow \text{zeros}(X.\text{shape})$ 
       $h[\text{row}, \text{col}] \leftarrow \text{eps}$ 
       $\text{grad}[\text{row}, \text{col}] \leftarrow \frac{f(X+h) - f(X)}{\text{eps}}$ 
    end for
  end for
  return  $\text{grad}$ 
end function
```

¹Extraídas del matrix cookbook <https://www.math.uwaterloo.ca/~hwolkowi/matrixcookbook.pdf>

4. Implemente un método de descenso por gradiente para encontrar un punto crítico de la función. Compare la solución y su valor funcional con la solución dada por la descomposición espectral de A .

4.1. Implementación

Implementaremos el método de descenso por gradiente acelerado.

Algorithm 2 Nesterov Gradient Descent

```

function NGD(grad,  $x_{\text{init}}$ ,  $\alpha$ , tol =  $1e - 5$ )
   $x \leftarrow x_{\text{init}}$ 
   $y \leftarrow x_{\text{init}}$ 
  iter  $\leftarrow 0$ 
  while  $|\text{grad}(y)| > \text{tol}$  do
     $x_{\text{next}} \leftarrow y - \alpha \cdot \text{grad}(y)$ 
     $y_{\text{next}} \leftarrow x_{\text{next}} + \frac{\text{iter}}{\text{iter}+3} \cdot (x_{\text{next}} - x)$ 
     $x, y \leftarrow x_{\text{next}}, y_{\text{next}}$ 
    iter  $\leftarrow \text{iter} + 1$ 
  end while
  return  $x$ 
end function

```

4.2. Comparación de Resultados

El método de Descenso por Gradiente a partir del X inicial proporcionado (elegido aleatoriamente) y utilizando un $\alpha = 1e - 3$ convergió en 293 a una "solución" que dista (ver referencia 1). Por otro lado, la diferencia entre los valores funcionales es de (ver referencia 2).

$$\|X_s v d - X_g d\| = 18,3445 \quad (1)$$

$$\|f(X_s v d) - f(X_g d)\| = 5,4570e - 12 \quad (2)$$